



Low resource speech translation: Quechua y Mapudungún

Pre-proyecto - NLP

Diego Barriga, Edgar Gazque

23 de Marzo 2026

Programa de Posgrado en Ciencia e Ingeniería de la Computación (PCIC)

Universidad Nacional Autónoma de México

Especificaciones del reto

Corpus

Propuesta

Registro

Table of Contents

Especificaciones del reto

Corpus

Propuesta

Registro

International Conference on Spoken Language Translation^a


- Conferencia anual líder en evaluación de sistemas de traducción de habla.
- Organiza *Shared Tasks* (tareas compartidas) para benchmark global.
- Fomenta la publicación de descripciones de sistemas y hallazgos científicos.



^a<https://iwslt.org/2026/low-resource>


Nuestra Participación: *Low-Resource* Track

- **Objetivo General:** El objetivo es evaluar y promover tecnologías de la traducción del habla (*speech translation, ST*) donde los datos son escasos.



Nuestra Participación: *Low-Resource* Track

- **Objetivo General:** El objetivo es evaluar y promover tecnologías de la traducción del habla (*speech translation, ST*) donde los datos son escasos.
- Participaremos en el *shared task* enfocado en lenguas de **bajos recursos digitales** (*low-resource languages*).



Track 1: Speech to text translation

- Realizaremos un sistema de *speech translation* para el track 1 el cual contempla 10 lenguas topológicamente diversas.

Track 1: Speech to text translation

- Realizaremos un sistema de *speech translation* para el track 1 el cual contempla 10 lenguas topológicamente diversas.
- Nos enfocaremos en lenguas habladas en América Latina, en partícula, pretendemos hacer un sistema multilingüe Mapuche-Quechua → Español.

¿Qué es End-to-End Speech Translation?

Enfoque Clásico (Cascada):

Audio → ASR → Texto Transcrito → MT → Texto Traducido

Problema: Propagación de errores.

Enfoque Directo (End-to-End):

Audio → Modelo Único → Texto Traducido

Ventaja: Menor latencia, no requiere transcripciones intermedias en entrenamiento.

Los modelos estándar de *Deep Learning* requieren miles de horas de audio alineado. Las lenguas originarias **carecen de estos recursos**.

Preguntas de Investigación (RQs):

1. **RQ1:** ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como el Quechua y Mapuche?

Preguntas de Investigación (RQs):

1. **RQ1:** ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como el Quechua y Mapuche?
2. **RQ2:** ¿Un enfoque de entrenamiento multilingüe (entrenar ambas lenguas indígenas a la vez hacia el español) mejora el rendimiento individual al **compartir características** acústicas/semánticas?

Preguntas de Investigación (RQs):

1. **RQ1:** ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como el Quechua y Mapuche?
2. **RQ2:** ¿Un enfoque de entrenamiento multilingüe (entrenar ambas lenguas indígenas a la vez hacia el español) mejora el rendimiento individual al **compartir características** acústicas/semánticas?
3. **RQ3:** ¿Qué técnicas de ajuste eficiente de parámetros (*Adapters*) son más efectivas ante una **asimetría severa** de datos (90h vs 2h)?

- Si bien se han mostrado fuertes progresos en el área utilizando *datasets* con recursos abundantes, muchas lenguas del mundo carecen de la cantidad de datos paralelos necesarios para modelos de aprendizaje profundo estándar.

- Si bien se han mostrado fuertes progresos en el área utilizando *datasets* con recursos abundantes, muchas lenguas del mundo carecen de la cantidad de datos paralelos necesarios para modelos de aprendizaje profundo estándar.
- La comunidad requiere pensar en **enfoques creativos** para aprovechar los pocos recursos disponibles y, así, lograr sistemas competitivos y útiles.

Table of Contents

Especificaciones del reto

Corpus

Propuesta

Registro

Mapuche (Mapudungún)

- **Familia:** Araucana.
- **Hablantes:** 100K - 260K [Zúñiga, 2006].
- **Países:** Chile, Argentina.
- **Características:** Lengua no clasificada [Zúñiga, 2006].

Características generales

Mapuche (Mapudungún)

- **Familia:** Araucana.
- **Hablantes:** 100K - 260K [Zúñiga, 2006].
- **Países:** Chile, Argentina.
- **Características:** Lengua no clasificada [Zúñiga, 2006].

Quechua

- **Familia:** Araucana.
- **Hablantes:** > 8M
- **Países:** Perú, Ecuador, Bolivia
- **Característica:** Aglutinante

Mapudungún (arn) [Duan et al., 2020]

- **Region:** Chile
- **Url:** huggingface.co/datasets/mengct00/Mapudungun_iwslt26

Mapudungún (arn) [Duan et al., 2020]

- **Region:** Chile
- **Url:** huggingface.co/datasets/mengct00/Mapudungun_iwslt26

Quechua (que) [Cardenas et al., 2018]

- **Region:** Ayacucho, Peru (Quechua Chanka ISO:quy) y Cusco, Peru (Quechua Collao ISO:quz)
- **Url:** github.com/johneortega/IWSLT2026_Quechua_data

Estadísticas del Dataset (IWSLT proporcionado) II

Se observa un **severo desbalance** entre las dos lenguas del corpus.

Métrica	Mapuche	Quechua
Horas de Audio	90	2
Frases Alineadas	42,000	698
Dominio	Narraciones, histórico	Educativo, frases cortas

Mapuche (Mapudungún)

Kimkevi chi l'awen' pewmamu pu. → Conoce el remedio a través de los sueños pues.

Mapuche (Mapudungún)

Kimkevi chi l'awen' pewmamu pu. → Conoce el remedio a través de los sueños pues.

Quechua

chaysi mana ancha qullqinpas kasqachu. → por eso es que no tenía mucho dinero

Características del texto I

Tamaño promedio de las palabras




Figura 1: Mapuche




Figura 2: Quechua

Características del texto II

Numero de caracteres




Figura 3: Mapuche




Figura 4: Quechua

Características del texto III

Numero de palabras por oracion




Figura 5: Mapuche




Figura 6: Quechua

Table of Contents

Especificaciones del reto

Corpus

Propuesta

Registro

Modelos preentrenados: Canary

Canary 1B v2 [Koluguri et al., 2025]. Un modelo de *1 Billion* de parámetros entrenado con al rededor de 1.7 millones de horas de 25 idiomas. En este trabajo también se entreno con lenguas de bajos recursos como Lituano.



Modelos preentrenados II: SeamlessM4T

Meta también tiene modelos como SeamlessM4T [Seamless Communication et al., 2023] con versiones de 1.2 y 2.3 *Billion* parámetros entrenado con 4.5 millones de horas. De igual forma integraron idiomas de bajos recursos en el entrenamiento, como el Uzbeko.



En ambos casos los pesos de los modelos están disponibles para uso libre.

Fine-tuning Eficiente (Adapters)

Dado que tenemos muy pocos datos, un *Full Fine-Tuning* causaría **overfitting** y es computacionalmente costoso. Nuestra Solución:

Dado que tenemos muy pocos datos, un *Full Fine-Tuning* causaría **overfitting** y es computacionalmente costoso. Nuestra Solución:

Parameter-Efficient Fine-Tuning (PEFT)

- Congelamos la mayoría de los pesos del modelo preentrenado (ej. `canary-1b-v2`).

- Congelamos la mayoría de los pesos del modelo preentrenado (ej. `canary-1b-v2`).
- Habilitamos pequeñas capas entrenables (**Adapters**) [Houlsby et al., 2019].

- Congelamos la mayoría de los pesos del modelo preentrenado (ej. `canary-1b-v2`).
- Habilitamos pequeñas capas entrenables (**Adapters**) [Houlsby et al., 2019].
- **Estrategia específica:** Entrenaremos adapters en el *Encoder* (para capturar la acústica de las nuevas lenguas) y, opcionalmente, en las capas de atención del *Decoder*.

Table of Contents

Especificaciones del reto


Corpus

Propuesta

Registro

Evidencia del registro

El registro se llevará a cabo a través de la página de la ACL¹. Hasta el momento de esta presentación dicho registro no se ha abierto.



¹<https://2026.aclweb.org/registration/>



Cardenas, R., Zevallos, R., Baquerizo, R., and Camacho, L. (2018).

Siminchik: A speech corpus for preservation of southern quechua.

ISI-NLP 2, page 21.



Duan, M., Fasola, C., Rallabandi, S. K., Vega, R. M., Anastasopoulos, A., Levin, L., and Black, A. W. (2020).

A resource for computational experiments on mapudungun.

-  Houlsby, N., Giurgiu, A., Jastrzebski, S., Morrone, B., de Laroussilhe, Q., Gesmundo, A., Attariyan, M., and Gelly, S. (2019).

Parameter-efficient transfer learning for nlp.

-  Koluguri, N. R., Sekoyan, M., Zelenfroynd, G., Meister, S., Ding, S., Kostandian, S., Huang, H., Karpov, N., Balam, J., Lavrukhin, V., Peng, Y., Papi, S., Gaido, M., Brutti, A., and Ginsburg, B. (2025).

Granary: Speech recognition and translation dataset in 25 european languages.



Seamless Communication, Barrault, L., Chung, Y.-A., Meglioli, M. C., Dale, D., Dong, N., Duppenthaler, M., Duquenne, P.-A., Ellis, B., Elsahar, H., Haaheim, J., Hoffman, J., Hwang, M.-J., Inaguma, H., Klaiber, C., Kulikov, I., Li, P., Licht, D., Maillard, J., Mavlyutov, R., Rakotoarison, A., Sadagopan, K. R., Ramakrishnan, A., Tran, T., Wenzek, G., Yang, Y., Ye, E., Evtimov, I., Fernandez, P., Gao, C., Hansanti, P., Kalbassi, E., Kallet, A., Kozhevnikov, A., Mejia, G., Roman, R. S., Touret, C., Wong, C., Wood, C., Yu, B., Andrews, P., Balioglu, C., Chen, P.-J., Costa-jussà, M. R., Elbayad, M., Gong, H., Guzmán, F., Heffernan, K., Jain, S., Kao, J., Lee, A., Ma, X., Mourachko, A., Peloquin, B., Pino, J., Popuri, S., Ropers, C.,

Saleem, S., Schwenk, H., Sun, A., Tomasello, P., Wang, C., Wang, J., Wang, S., and Williamson, M. (2023).

Seamless: Multilingual expressive and streaming speech translation.



Zúñiga, F. (2006).

Mapudungun: El habla mapuche.

Centro de Estudios Públicos, Santiago, Chile.

¿Preguntas?

Contacto:

Diego Barriga - `dbarriga@ciencias.unam.mx`

Edgar Gazque - `amilkar.edgar@gmail.com`