



Low resource speech translation

Una arquitectura de *fine-tuning* eficiente para el Mapudungún

Diego Barriga, Edgar Gazque

dbarriga@ciencias.unam.mx, amilkar@ciencias.unam.mx

25 de Mayo 2026

Procesamiento del Lenguaje Natural

Programa de Posgrado en Ciencia e Ingeniería de la Computación (PCIC)

Universidad Nacional Autónoma de México

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

- La traducción automática (*Machine Translation, MT*) es una tarea del Lingüística Computacional icónica.

¹<https://www.nytimes.com/1954/01/08/archives/russian-is-turned-into-english-by-a-fast-electronic-translator.html>

- La traducción automática (*Machine Translation, MT*) es una tarea del Lingüística Computacional icónica.
- La primera demostración pública de un sistema de traducción automática data de 1954¹

¹<https://www.nytimes.com/1954/01/08/archives/russian-is-turned-into-english-by-a-fast-electronic-translator.html>

- La traducción automática (*Machine Translation, MT*) es una tarea del Lingüística Computacional icónica.
- La primera demostración pública de un sistema de traducción automática data de 1954¹
- El reporte *ALPAC, Automatic Language Processing Advisory Committee* de 1966 concluyó que la traducción automática no era viable.

¹<https://www.nytimes.com/1954/01/08/archives/russian-is-turned-into-english-by-a-fast-electronic-translator.html>

Made in Turkey

Fabrique en Turquie

Hecho en Pavo

CA33223

EROS CLOTHING INC.

Adopción de la tecnología



Figura 1: Traducción automática en un servicio en línea

<https://libretranslate.com/>.

Reconocimiento automático del habla

- El reconocimiento automático del habla (*Automatic Speech Recognition, ASR*) es una tarea que busca convertir audio en texto.
- Se utiliza en aplicaciones como asistentes de voz, transcripción de reuniones, y sistemas de dictado.

Featured Transcription

Tetelcingo Nahuatl

ISO Code: nhg

Family

Uto-Aztecan

Script ⓘ

Latin or Latin-based (a...z)



amo naah noyulcou, yen noncan noprino tirso sen tichichi ihquipia,
uan ica quipia icinturon tepetzen pero quemeh si fuera naah
nochichi inon ivisnotlac motlatliah queh petzteca pues, pero
yevatica notla ihquih mihquiyi eh, una amo nochichi inon, uan tos
yeh inon, pero, oh, quemach iquemanoh uan, oyaya notlah ihquin,
oniconita, oniconitaya cafen pero osentepouitz, me imagino,

Figura 2: Ejemplo de sistema de reconocimiento automático del habla.

Tomada de

<https://aidemos.atmeta.com/omnilingualasr/language-globe>

- La traducción automática del habla (*Speech Translation, ST*) es una tarea que combina el reconocimiento automático del habla (*Automatic Speech Recognition, ASR*) con la traducción automática (*MT*).
- El objetivo es traducir el **audio de una lengua a texto en otra lengua**.




Figura 3: Ejemplo de sistema de traducción automática del habla. Ingresa audio en una lengua y sale texto en otra lengua.

- En los últimos años, se ha optado por utilizar un enfoque *encoder-decoder* basado en redes neuronales profundas, con modelos como Transformers [Vaswani et al., 2017].

- En los últimos años, se ha optado por utilizar un enfoque *encoder-decoder* basado en redes neuronales profundas, con modelos como Transformers [Vaswani et al., 2017].
- En particular, se aprovechan modelos masivos pre-entrenados de forma *end-to-end* para tareas de traducción automática y reconocimiento del habla.

- En los últimos años, se ha optado por utilizar un enfoque *encoder-decoder* basado en redes neuronales profundas, con modelos como Transformers [Vaswani et al., 2017].
- En particular, se aprovechan modelos masivos pre-entrenados de forma *end-to-end* para tareas de traducción automática y reconocimiento del habla.
- Estos modelos aprenden a mapear de un audio a su representación textual.

- En los últimos años, se ha optado por utilizar un enfoque *encoder-decoder* basado en redes neuronales profundas, con modelos como Transformers [Vaswani et al., 2017].
- En particular, se aprovechan modelos masivos pre-entrenados de forma *end-to-end* para tareas de traducción automática y reconocimiento del habla.
- Estos modelos aprenden a mapear de un audio a su representación textual.
- Para adaptar estos modelos a tareas específicas, se utiliza el **ajuste fino** (*fine-tuning*), donde se entrena el modelo con un conjunto de datos específico para la tarea.




Figura 4: Arquitectura *encoder-decoder* para traducción automática.
Tomada de [Jurafsky and Martin, 2026]

¿Qué es End-to-End Speech Translation?

Enfoque clásico

Audio → ASR → Texto Transcrito → MT → Texto Traducido

Problema: Propagación de errores.

Enfoque directo (*end-to-end*)

Audio → Modelo Único → Texto Traducido

Ventaja: Menor latencia, no requiere transcripciones intermedias en entrenamiento.

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

Diversidad lingüística en América Latina

- América Latina es una región con una gran diversidad lingüística, albergando cientos de lenguas originarias.

Diversidad lingüística en América Latina

- América Latina es una región con una gran diversidad lingüística, albergando cientos de lenguas originarias.
- Limitandonos a México, existen 68 lenguas originarias reconocidas oficialmente, con más de 360 variantes dialectales.

Diversidad lingüística en América Latina

- América Latina es una región con una gran diversidad lingüística, albergando cientos de lenguas originarias.
- Limitandonos a México, existen 68 lenguas originarias reconocidas oficialmente, con más de 360 variantes dialectales.
- Todas las lenguas originarias de México son de **bajos recursos digitales**. Una realidad para muchas lenguas originarias en América Latina.

Diversidad lingüística en América Latina

- América Latina es una región con una gran diversidad lingüística, albergando cientos de lenguas originarias.
- Limitandonos a México, existen 68 lenguas originarias reconocidas oficialmente, con más de 360 variantes dialectales.
- Todas las lenguas originarias de México son de **bajos recursos digitales**. Una realidad para muchas lenguas originarias en América Latina.
- Hay muy poca tecnología del lenguaje desarrollada para estas lenguas.

Diversidad lingüística en América Latina

- América Latina es una región con una gran diversidad lingüística, albergando cientos de lenguas originarias.
- Limitandonos a México, existen 68 lenguas originarias reconocidas oficialmente, con más de 360 variantes dialectales.
- Todas las lenguas originarias de México son de **bajos recursos digitales**. Una realidad para muchas lenguas originarias en América Latina.
- Hay muy poca tecnología del lenguaje desarrollada para estas lenguas.
- La mayoría de las lenguas originarias no tienen sistema de escritura estandarizado. Son **lenguas principalmente orales**.




Figura 5: Lenguas originarias de México. Tomada de la práctica 2 del Lingüística Computacional del alumno @romanbott

Los modelos estándar de *encoder-decoder* usando *transformers* requieren miles de horas de audio alineado. Las lenguas originarias **carecen de estos recursos**.

Preguntas de Investigación:

1. ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como las lenguas originarias?

Preguntas de Investigación:

1. ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como las lenguas originarias?
2. ¿Un entrenamiento *end-to-end* tendrá un **mejor desempeño que un sistema de cascada** (ASR + MT) en este entorno de bajos recursos?

Preguntas de Investigación:

1. ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como las lenguas originarias?
2. ¿Un entrenamiento *end-to-end* tendrá un **mejor desempeño que un sistema de cascada** (ASR + MT) en este entorno de bajos recursos?
3. ¿Qué técnicas de ajuste eficiente de parámetros son efectivas en este entorno?

Preguntas de Investigación:

1. ¿Es posible **transferir conocimiento** de modelos masivos pre-entrenados en lenguas mayoritarias hacia lenguas con tipologías drásticamente distintas como las lenguas originarias?
2. ¿Un entrenamiento *end-to-end* tendrá un **mejor desempeño que un sistema de cascada** (ASR + MT) en este entorno de bajos recursos?
3. ¿Qué técnicas de ajuste eficiente de parámetros son efectivas en este entorno?
4. ¿Un enfoque de entrenamiento multilingüe mejora el rendimiento individual al **compartir características** acústicas/semánticas?

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

International Conference on Spoken Language Translation^a

- Conferencia anual líder en evaluación de sistemas de traducción de habla.
- Organiza *Shared Tasks* (tareas compartidas) para benchmark global.
- Fomenta la publicación de descripciones de sistemas y hallazgos científicos.



^a<https://iwslt.org/2026/low-resource>

- **Objetivo General:** El objetivo es evaluar y promover tecnologías de la traducción del habla (*speech translation, ST*) donde los datos son escasos.

- **Objetivo General:** El objetivo es evaluar y promover tecnologías de la traducción del habla (*speech translation, ST*) donde los datos son escasos.
- Participamos en el *shared task* enfocado en lenguas de **bajos recursos digitales** (*low-resource languages*).

Track 1: Speech to text translation

- Realizamos un sistema de *speech translation* para el track 1 el cual contempla 10 lenguas topológicamente diversas.

Track 1: Speech to text translation

- Realizamos un sistema de *speech translation* para el track 1 el cual contempla 10 lenguas topológicamente diversas.
- Nos enfocamos en lenguas habladas en América Latina, en partícula, **realizamos un sistema monolingüe** Mapuche → Español.

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

Ajuste fino (*Fine-Tuning*)

- El ajuste fino es una técnica de transferencia de aprendizaje donde un modelo pre-entrenado se adapta a una tarea específica con un conjunto de datos más pequeño.

Ajuste fino (*Fine-Tuning*)

- El ajuste fino es una técnica de transferencia de aprendizaje donde un modelo pre-entrenado se adapta a una tarea específica con un conjunto de datos más pequeño.
- Los modelos masivos pre-entrenados ya han aprendido representaciones lingüísticas generales, el ajuste fino es una estrategia para adaptar estos modelos a tareas específicas con pocos datos.





Figura 6: Transferencia de conocimiento de un modelo pre-entrenado a otra tarea. Tomada de clase 7 del curso Analítica de Textos y Modelos de Lenguaje derivada de <https://somosnlp.org/nlp-de-cero-a-cien/sesion-04>.

Fine-tuning Eficiente (PEFT)


En el contexto de los bajos recursos, un *Full FineTuning* causaría **overfitting** y es computacionalmente costoso.



Nuestra propuesta:

Fine-tuning Eficiente (PEFT)


En el contexto de los bajos recursos, un *Full FineTuning* causaría **overfitting** y es computacionalmente costoso.



Nuestra propuesta: **Parameter-Efficient Fine-Tuning (PEFT)**
[Xu et al., 2023]

Houlsby Adapter [Houlsby et al., 2019]

En la implementacion llamado *Linear adapter*



Caracteristicas: Modulo Linear Feedforward, LayerNorm, Una sola capa oculta con funcion de activacion.

Características del adapter [He et al., 2021]

- **Funcional:** Los parametros entrenables que modificaran el *input*
- **Inserción:** Las salidas del adaptador se integran con la entrada original.
- **Composición:** Cómo se integran las salidas de los adaptadores con las entradas. Ejemplo una conexión de suma residual o multiplicacion elemento a elemento.

Adapters para ST de lenguas originarias

- Se congelan la mayoría de los pesos de un modelo preentrenado (ej. `canary-1b-v2`).

Adapters para ST de lenguas originarias

- Se congelan la mayoría de los pesos de un modelo preentrenado (ej. `canary-1b-v2`).
- Se habilitan pequeñas capas entrenables.

Adapters para ST de lenguas originarias

- Se congelan la mayoría de los pesos de un modelo preentrenado (ej. canary-1b-v2).
- Se habilitan pequeñas capas entrenables.
- **Estrategia específica:** Entrenaremos adapters en el *Encoder* para capturar la acústica de las nuevas lenguas.

Adapters para ST de lenguas originarias

- Se congelan la mayoría de los pesos de un modelo preentrenado (ej. canary-1b-v2).
- Se habilitan pequeñas capas entrenables.
- **Estrategia específica:** Entrenaremos adapters en el *Encoder* para capturar la acústica de las nuevas lenguas.
- Con esta configuración entrenamos 589,824 parámetros de un total de 962,745,344, es decir menor al 0.1 %

Modelos pre-entrenados: Canary

Canary 1B v2 [Koluguri et al., 2025]. Un modelo de *1 Billion* de parámetros entrenado con al rededor de 1.7 millones de horas de 25 idiomas. En este trabajo también se entreno con lenguas de bajos recursos como Lituano.



- Canary es un modelo de tipo *encoder-decoder* basado en la arquitectura Conformer [Gulati et al., 2020] y en particular en la variante Fast Conformer [Rekesh et al., 2023].

Canary como modelo base

- Canary es un modelo de tipo *encoder-decoder* basado en la arquitectura Conformer [Gulati et al., 2020] y en particular en la variante Fast Conformer [Rekesh et al., 2023].
- Fue entrenado de forma multilingüe y multitarea (*ASR* y *ST*)

Canary como modelo base

- Canary es un modelo de tipo *encoder-decoder* basado en la arquitectura Conformer [Gulati et al., 2020] y en particular en la variante Fast Conformer [Rekesh et al., 2023].
- Fue entrenado de forma multilingüe y multitarea (*ASR* y *ST*)
- El modelo original fue entrenado con 1.7 millones de horas de audio en 22 idiomas de grandes recursos y 3 idiomas de bajos recursos.

Canary como modelo base

- Canary es un modelo de tipo *encoder-decoder* basado en la arquitectura Conformer [Gulati et al., 2020] y en particular en la variante Fast Conformer [Rekesh et al., 2023].
- Fue entrenado de forma multilingüe y multitarea (*ASR* y *ST*)
- El modelo original fue entrenado con 1.7 millones de horas de audio en 22 idiomas de grandes recursos y 3 idiomas de bajos recursos.
- Utilizamos este modelo para realizar una **corrida experimental inicial**.




Figura 7: Arquitectura de Canary con Adapters lineales. Código en <https://github.com/umoqnier/iwstl-low-resource-experiments/>

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

Mapuche (Mapudungún)

- **Familia:** Araucana.
- **Hablantes:** 100K - 260K [Zúñiga, 2006].
- **Países:** Chile, Argentina.
- **Características:** Lengua no clasificada [Zúñiga, 2006].

Estadísticas del Dataset (IWSLT proporcionado)

Métrica		Mapuche
Horas de Audio		90
Frases Alineadas		42,000
Dominio	Narraciones, histórico	

Características del Texto (Mapudungun)




Figura 8: Longitud de palabra




Figura 9: Longitud de caracteres




Figura 10: Longitud de oración

Pipeline dinámico

- Implementación de un flujo de aumentación de datos de forma *on-the-fly* basado en [Jordal, 2023].
- Aplicado directamente durante el entrenamiento.
- Eliminamos la necesidad de almacenar datos pre-procesados adicionales.

Técnicas estocásticas

- Inyección de ruido de fondo y ruido gaussiano.
- Aplicación de *aliasing* y respuestas al impulso de sala (*room impulse responses*).
- Filtrado de paso de banda (*band-pass filtering*).
- Desplazamiento de tono (*pitch shifting*).

Ejemplo

- ▶ **Audio** → coñoepan soy yo aquí en esta tierra nació tierra de cahuemu isla huapi se llama

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

- El *Word Error Rate*, *WER* y el *BLEU* de entrenamiento decreció como se esperaba.

- El *Word Error Rate*, *WER* y el *BLEU* de entrenamiento decreció como se esperaba.
- Agregamos un modulo de aumentación de datos que **no ayudó** a mejorar el desempeño.

- El *Word Error Rate*, *WER* y el *BLEU* de entrenamiento decreció como se esperaba.
- Agregamos un modulo de aumentación de datos que **no ayudó** a mejorar el desempeño.
- Un análisis cualitativo muestra que el modelo si alcanza a capturar fenomenos del habla del Mapudungún. Ver ejemplo 1.

- El *Word Error Rate*, *WER* y el *BLEU* de entrenamiento decreció como se esperaba.
- Agregamos un modulo de aumentación de datos que **no ayudó** a mejorar el desempeño.
- Un análisis cualitativo muestra que el modelo si alcanza a capturar fenomenos del habla del Mapudungún. Ver ejemplo 1.
- Sin embargo, el modelo tiende a caer en la repetición de estructuras básicas del español. Ver ejemplo 2.

Run	WER on dev	BLUE on dev
Main	2,5	1,015
Vanilla	2,3	1,05
Filtered	1,56	3,7

Cuadro 1: Main: Corrita principal, incluye el modulo de aumentación de datos. **Vanilla:** No incluye aumentación de datos. **Filtered:** Corrita sin el modulo de aumentación de datos y con los audios de menos de 15 segundos. El resto de audios fue usado para pruebas.

Primera version




Figura 11: Primera corrida experimental.

Segunda version I




Figura 12: Segunda corrida experimental.




Figura 13: Tercera corrida experimental.

1. Transcripción adecuada de palabras raras

*Referencia: sí pero yo creo que hay eso sí que no sé pero
en las cosas del huinca parece que hay una tableta*

*Predicción: sí pero yo creo que hay eso sí que no sé pero
en el huinca parece que hay una tableta*

2. Decodificación repetitiva

Referencia: en el monte en la quebrada esta en la montaña

Predicción: en la tierra de la tierra de la tierra



Figura 14: Portada del paper de la participación en IWSLT 2026.

Table of Contents

Traducción automática

Problemática

Especificaciones del reto

Propuesta

Corpus

Resultados

Conclusiones y trabajo futuro

- **Adaptación de Modelos:** Presentamos un enfoque para adaptar un modelo fundacional multilingüe y multitarea para la traducción de voz a texto de Mapudungun a Español.
- **Viabilidad Técnica:** A pesar de las limitaciones de recursos, la metodología logró capturar características fonéticas distintivas del Mapudungun, demostrando la eficacia del ajuste fino eficiente (*PEFT*).

Trabajo futuro

- Utilizar una lengua de bajos recursos mas cercana al Mapudungún como placeholder para el entrenamiento.
- Realizar experimentación adicional con diferentes estrategias de *PEFT* y arquitecturas de modelos para mejorar el desempeño.
- Planeamos extender este marco de trabajo para desarrollar sistemas de traducción multilingües más amplios que incluyan otras lenguas originarias latinoamericanas, como el Quechua y el Náhuatl.
- El objetivo final es **reducir la brecha tecnológica entre lenguas** de altos y bajos recursos, asegurando que estas voces estén representadas en las tecnologías de voz modernas.



Gulati, A., Qin, J., Chiu, C.-C., Parmar, N., Zhang, Y., Yu, J., Han, W., Wang, S., Zhang, Z., Wu, Y., and Pang, R. (2020).

Conformer: Convolution-augmented transformer for speech recognition.



He, J., Zhou, C., Ma, X., Berg-Kirkpatrick, T., and Neubig, G. (2021).

Towards a unified view of parameter-efficient transfer learning.

CoRR, abs/2110.04366.

-  Houlsby, N., Giurgiu, A., Jastrzebski, S., Morrone, B., de Laroussilhe, Q., Gesmundo, A., Attariyan, M., and Gelly, S. (2019).

Parameter-efficient transfer learning for NLP.

CoRR, abs/1902.00751.

-  Jordal, I. (2023).

Audiomentations: A python library for audio data augmentation.

<https://iver56.github.io/audiomentations/>.

Accessed: 2026-04-23.



Jurafsky, D. and Martin, J. H. (2026).

Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models.

3rd edition.

Online manuscript released January 6, 2026.



Koluguri, N. R., Sekoyan, M., Zelenfroynd, G., Meister, S., Ding, S., Kostandian, S., Huang, H., Karpov, N., Balam, J., Lavrukhin, V., Peng, Y., Papi, S., Gaido, M., Brutti, A., and Ginsburg, B. (2025).

Granary: Speech recognition and translation dataset in 25 european languages.



Rekesh, D., Koluguri, N. R., Krizan, S., Majumdar, S., Noroozi, V., Huang, H., Hrinchuk, O., Puvvada, K., Kumar, A., Balam, J., and Ginsburg, B. (2023).

Fast conformer with linearly scalable attention for efficient speech recognition.



Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017).

Attention is all you need.

In *Neural Information Processing Systems (NeurIPS)*.

-  Xu, L., Xie, H., Qin, S.-Z. J., Tao, X., and Wang, F. L. (2023).
Parameter-efficient fine-tuning methods for pretrained language models: A critical review and assessment.
-  Zúñiga, F. (2006).
Mapudungun: El habla mapuche.
Centro de Estudios Públicos, Santiago, Chile.

¿Preguntas?

Contacto:

Diego Barriga - `dbarriga@ciencias.unam.mx`

Edgar Gazque - `amilkar@ciencias.unam.mx`